

Master MIAGE / Structuration de documents

Enseignant : Hendry FERREIRA CHAME

PROJET : NUAGE DE MOTS D'ACTUALITÉ

SYNOPSIS

Grâce à la généralisation d'Internet et des technologies mobiles, l'information nous entoure, ce qui facilite de nombreuses tâches mais en complique paradoxalement d'autres en raison du volume considérable de données à traiter. Pour des activités telles que la vérification des faits, la recherche et le journalisme, il serait avantageux de pouvoir collecter des informations provenant de sources fiables dans un domaine particulier. Ainsi, l'objectif principal de ce projet est de développer un système de collecte et de visualisation d'informations sous forme de nuage de mots construit à partir de titres de l'actualité. Cette application doit permettre aux utilisateurs de s'abonner à plusieurs sources d'actualités (via la méthode [sitemap](#) de Google), et d'organiser ces informations pour consultation dans une base de données NoSQL MongoDB.



EXIGENCES FONCTIONNELLES

L'application doit fonctionner en mode **administration** et en mode **consultation**. En mode administration, l'utilisateur peut gérer ses abonnements aux sites d'actualités. En mode consultation, l'utilisateur peut parcourir les titres d'actualités au format web, interroger les données en spécifiant un intervalle de temps ou par mots et créer une représentation sous forme de nuage de mots au format graphique [SVG](#).

Mode Administration : gestion d'abonnements

Les opérations possibles en mode administration sont :

- Abonnement à un plan de site ([sitemap](#)).
- Suppression d'un abonnement.
- Définition des minuteries (normalement à l'échelle des heures ou des jours) pour récupérer les nouvelles informations publiées par les sources.

Voici un exemple de sitemap (https://www.lemonde.fr/sitemap_news.xml) :

```


Aucune information de style ne semble associée à ce fichier XML. L'arbre du document est affiché ci-dessous.

- <urlset>
- <url>
- <loc>
  https://www.lemonde.fr/politique/live/2026/03/09/en-direct-municipales-2026-retrouvez-les-dernieres-prises-de-parole-des-candidats-et-suivez-la-fin-la-campagne_6670061_823448.html
</loc>
<lastmod>2026-03-09T17:22:06+01:00</lastmod>
- <news:news>
  <news:publication_date>2026-03-09T17:22:06+01:00</news:publication_date>
  - <news:title>
    EN DIRECT, municipales 2026 : retrouvez les dernières prises de parole des candidats et suivez la fin de la campagne
  </news:title>
  - <news:publication>
    <news:name>Le Monde</news:name>
    <news:language>fr</news:language>
  </news:publication>
</news:news>
- <image:image>
- <image:loc>
  https://img.lemde.fr/2026/03/06/500/0/6000/3000/1440/720/60/0/bbce50f_ftp-1-a2ywqmdy7kbj-2026-03-06t120000z-1072343940-rc2xyja1azx7-rtrmadp-3-france-election-paris.JPG
</image:loc>
- <image:caption>
  Un homme passe devant les affiches des candidats aux élections municipales de Paris, 6 mars 2026.
</image:caption>
</image:image>
</url>
- <url>

```

Mode consultation : aperçu des articles et nuage de mots

L'utilisateur peut parcourir les articles d'actualité globalement ou par source, date de publication, texte ou catégorie de mots-clés. De plus, il doit pouvoir cliquer sur le titre d'un article pour accéder à son site web dans un nouvel onglet ; l'horodatage de cette action doit être enregistré, permettant ainsi la recherche d'articles par date et heure de consultation. Voici une représentation de l'interface utilisateur :



Enfin, l'utilisateur doit pouvoir générer, afficher et télécharger un nuage de mots au format [SVG](#) représentant les n (ce parametre doit être sélectionnable) mots les plus fréquents dans les titres pendant une période donnée.

EXIGENCES NON FONCTIONNELLES

Le projet doit être développé en tant qu'application web compatible avec la plupart des navigateurs (Firefox, Edge, Chrome, Safari), en langage de programmation Python (version ≥ 3.8) et utiliser l'API

MongoDB (voici la documentation de [PyMongo](#)). L'interface utilisateur sera développée dans le micro framework web [Flask](#).

Le projet doit prendre en compte l'efficacité des requêtes pour la recherche d'informations et la construction du nuage de mots SVG.

L'utilisation d'IA générative pour répondre aux exigences de ce projet est interdite. Il s'agit d'une activité académique qui doit être réalisée par votre équipe de projet. Ce document est protégé par le droit d'auteur et ne doit pas être diffusé sur des plateformes d'IA en ligne.

RAPPORT DE PROJET


Le rapport de projet doit justifier les choix effectués lors de la conception du schéma de données, en précisant par exemple si les modèles de structuration de documents étudiés en cours ont été utilisés, ou encore le type d'indexation de documents employé. Vous devez y expliquer votre approche en matière d'optimisation des requêtes et de construction du nuage de mots. Un diagramme de l'organisation de la base de données (collections, documents et leur imbrication) doit également y figurer.

Plan de rapport (donné à titre indicatif)

1. *Introduction*
2. *Conception*. Présentation des choix effectués : structuration de documents, patterns, indexation, parmi d'autres.
3. *Développement*. Structuration de vos sources, bilan de fonctionnalités assurées dans votre projet. Dans le cas où vous n'avez pas assuré l'intégralité des fonctionnalités, veuillez justifier.
4. *Conclusions et perspectives*. Réflexion critique sur la pertinence de MongoDB au regard des objectifs du projet, ou sur les défis que cette technologie pourrait poser. Points forts et points faibles rencontrés dans le projet, et pistes d'amélioration.

LE TRAVAIL À RENDRE

- **Rendu** : Déposer un seul fichier en format ZIP contenant. Voici le contenu attendu :



Ce fichier ZIP doit être nommé selon la convention suivante :

NOM_membre1_NOM_Membre2_NOM_membre3_NOM_membre4.zip

Par exemple, soit une équipe constituée par MERLEAU-PONTY Maurice, GALOIS Évariste, LOVELACE Ada et CURIE Marie, le fichier doit être nommé :

« MERLEAU-PONTY_GALOIS_LOVELACE_CURIE.zip »

Notez que le non-respect de ces consignes sera pénalisé sur la note du projet.

- **Base de données :**

- Vous n'avez pas à rendre votre base de données.
- S'agissant d'un projet académique, pour faciliter son évaluation, votre application cliente ne doit pas établir de connexion authentifiée à MongoDB. Utilisez simplement la chaîne de connexion « mongodb://localhost:27017 », soit :

```
from pymongo import MongoClient
...
client = MongoClient('localhost', 27017)
```

- La BD doit être nommée « SD2026_projet ».
- Vos collections doivent être nommées selon la convention suivante :

« G_{initiale nom 1, ... , initiale nom 4}_nomDeCollection ».

Par exemple, supposons un quadrinôme intégré par Jean **DUPONT**, Marie **FUSS**, Pierre **SCHAEFFER** et Pauline **BRIOT** et une collection **auteurs**, selon cette convention, la collection doit être nommée « G_DFSB_auteurs ».

CONDITIONNEMENT

Travail en quadrinôme à déposer sur Arche **au plus tard le dimanche 1 juin à 23h59**.

Attention au plagiat : il est indispensable d'agir de façon éthique. Le plagiat sera pénalisé tant au niveau du partage qu'au niveau de la copie. Par ailleurs, **l'utilisation d'IA générative pour répondre aux exigences de ce projet est interdite**. Il s'agit d'une activité académique qui doit être réalisée par votre équipe de projet. Ce document est protégé par le droit d'auteur et ne doit pas être diffusé sur des plateformes d'IA en ligne.